

Исследование стартапов

Цель и задачи исследования

Цель исследования - Исследовать динамику и структуру финансирования стартапов, чтобы выявить закономерности венчурного рынка и оценить устойчивость возврата средств. На основе этих данных сформировать инвестиционные рекомендации по покупке и развитию перспективных компаний в условиях 2015 года.

Задачи:

- Проанализировать компании в зависимости от сроков финансирования;
 - Классифицировать сегменты рынка на массовые, средние и нишевые;
 - Исследовать распределение и аномальные значения объёмов финансирования;
 - Сравнить популярность и объёмы разных типов финансирования.
 - Проанализировать динамику инвестиционных раундов и объёмов финансирования по годам;
 - Рассчитать долю возврата средств для разных типов финансирования;
 - Сформировать рекомендации по направлениям инвестирования.
-

Данные

В исследовании использованы два набора данных:

Основной датасет — `cb_investments.zip`. Внутри архива один файл — `cb_investments.csv`

Дополнительный датасет — `cb_returns.csv`.

Описание датасета `cb_investments.csv`:

- `name` — название компании.
- `homepage_url` — ссылка на сайт компании.
- `category_list` — категории, в которых работает компания. Указываются через `|`.
- `market` — основной рынок или отрасль компании.
- `funding_total_usd` — общий объём привлечённых инвестиций в долларах США.
- `status` — текущий статус компании, например `operating`, `closed` и так далее.
- `country_code` — код страны, например USA.
- `state_code` — код штата или региона, например, CA.
- `region` — регион, например, SF Bay Area.
- `city` — город, в котором расположена компания.
- `funding_rounds` — общее число раундов финансирования.
- `participants` — число участников в раундах финансирования.
- `founded_at` — дата основания компании.
- `founded_month` — месяц основания в формате `YYYY-MM`.
- `founded_quarter` — квартал основания в формате `YYYY-QN`.
- `founded_year` — год основания.
- `first_funding_at` — дата первого финансирования.
- `mid_funding_at` — дата среднего по времени раунда финансирования.
- `last_funding_at` — дата последнего финансирования.

- `seed` — сумма инвестиций на посевной стадии.
- `venture` — сумма венчурных инвестиций.
- `equity_crowdfunding` — сумма, привлечённая через долевого краудфандинг.
- `undisclosed` — сумма финансирования нераскрытого типа.
- `convertible_note` — сумма инвестиций через конвертируемые займы.
- `debt_financing` — сумма долгового финансирования.
- `angel` — сумма инвестиций от бизнес-ангелов.
- `grant` — сумма полученных грантов.
- `private_equity` — сумма инвестиций в виде прямых (частных) вложений.
- `post_ipo_equity` — сумма финансирования после IPO.
- `post_ipo_debt` — сумма долгового финансирования после IPO.
- `secondary_market` — сумма сделок на вторичном рынке.
- `product_crowdfunding` — сумма, привлечённая через продуктовый краудфандинг.
- `round_A` — `round_H` — сумма инвестиций в соответствующем раунде.

Описание датасета `cb_returns.csv` :

- `year` — год возврата средств.
- `seed` — сумма возвратов от посевных инвестиций.
- `venture` — сумма возвратов от венчурных инвестиций.
- `equity_crowdfunding` — сумма, возвращённая по долевого краудфандингу.
- `undisclosed` — сумма возвратов нераскрытого типа.
- `convertible_note` — сумма возвратов через конвертируемые займы.
- `debt_financing` — сумма возвратов от долгового финансирования.
- `angel` — сумма возвратов бизнес-ангелам.
- `grant` — сумма возвратов по грантам.
- `private_equity` — сумма возвратов прямых (частных) вложений.
- `post_ipo_equity` — сумма возвратов от IPO.
- `post_ipo_debt` — сумма возвратов от долгового IPO.
- `secondary_market` — сумма возвратов от сделок на вторичном рынке.
- `product_crowdfunding` — сумма возвратов по продуктового краудфандингу.

Содержимое проекта

1. Загрузка и предобработка данных
2. Исследовательский анализ по срокам финансирования и сегментам рынка
3. Работа с выбросами а анализ
4. Анализ динамики
5. Итоговый вывод и рекомендации

Загрузка и предобработка данных

Загрузка и первичный анализ данных

```
In [1]: import pandas as pd
pd.set_option('display.max_columns', None)
pd.set_option('display.float_format', '{:,.2f}'.format)
```

```
import matplotlib.pyplot as plt
import seaborn as sns

import warnings
warnings.filterwarnings('ignore')
```

```
In [2]: investments = pd.read_csv('data/cb_investments.csv', sep=';', low_memory=False)
returns = pd.read_csv('data/cb_returns.csv')
```

Сохраним изначальное количество строк для подсчета размера оставшего датасета а выводе по разделу.

```
In [3]: original_size = investments.shape[0]
```

Функция для вывода информации о данных

```
In [4]: def view_info(df):
    print('-----')
    print('Информация о таблице')
    print('-----')
    df.info()
    print('-----')
    print('Случайные строки датасета')
    display(df.sample(5))
    print('-----')
    print('Информация о пропусках')
    display(round(df.isna().mean()*100, 1))
```

Выводим информацию по 1-ой таблице

```
In [5]: view_info(investments)
```

Информация о таблице

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 54294 entries, 0 to 54293

Data columns (total 40 columns):

#	Column	Non-Null Count	Dtype
0	name	49437 non-null	object
1	homepage_url	45989 non-null	object
2	category_list	45477 non-null	object
3	market	45477 non-null	object
4	funding_total_usd	49438 non-null	object
5	status	48124 non-null	object
6	country_code	44165 non-null	object
7	state_code	30161 non-null	object
8	region	44165 non-null	object
9	city	43322 non-null	object
10	funding_rounds	49438 non-null	float64
11	participants	30473 non-null	float64
12	founded_at	38554 non-null	object
13	founded_month	38482 non-null	object
14	founded_quarter	38482 non-null	object
15	founded_year	38554 non-null	float64
16	first_funding_at	49438 non-null	object
17	mid_funding_at	30288 non-null	object
18	last_funding_at	49438 non-null	object
19	seed	49438 non-null	float64
20	venture	49438 non-null	float64
21	equity_crowdfunding	49438 non-null	float64
22	undisclosed	49438 non-null	float64
23	convertible_note	49438 non-null	float64
24	debt_financing	49438 non-null	float64
25	angel	49438 non-null	float64
26	grant	49438 non-null	float64
27	private_equity	49438 non-null	float64
28	post_ipo_equity	49438 non-null	float64
29	post_ipo_debt	49438 non-null	float64
30	secondary_market	49438 non-null	float64
31	product_crowdfunding	49438 non-null	float64
32	round_A	49438 non-null	float64
33	round_B	49438 non-null	float64
34	round_C	49438 non-null	float64
35	round_D	49438 non-null	float64
36	round_E	49438 non-null	float64
37	round_F	49438 non-null	float64
38	round_G	49438 non-null	float64
39	round_H	49438 non-null	float64

dtypes: float64(24), object(16)

memory usage: 16.6+ MB

Случайные строки датасета

	name	homepage_url	category_list	market	funding_total_usd	st
21238	Kudarom	http://kudarom.com	Hospitality	Hospitality		- oper
34826	Carreira Beauty	http://carreirabeauty.com/	E-Commerce Small and Medium Businesses Market...	E-Commerce		- oper
4193	Skycross	http://www.skycross.com	Manufacturing	Manufacturing	4,12,99,476	oper
21884	GeneWeave Biosciences	http://www.geneweave.com	Biotechnology	Biotechnology	2,49,99,998	oper
8648	mDialog	http://www.mdialog.com	Advertising	Advertising	80,27,970	acq



Информация о пропусках
name 8.90
homepage_url 15.30
category_list 16.20
market 16.20
funding_total_usd 8.90
status 11.40
country_code 18.70
state_code 44.40
region 18.70
city 20.20
funding_rounds 8.90
participants 43.90
founded_at 29.00
founded_month 29.10
founded_quarter 29.10
founded_year 29.00
first_funding_at 8.90
mid_funding_at 44.20
last_funding_at 8.90
seed 8.90
venture 8.90
equity_crowdfunding 8.90
undisclosed 8.90
convertible_note 8.90
debt_financing 8.90
angel 8.90
grant 8.90
private_equity 8.90
post_ipo_equity 8.90
post_ipo_debt 8.90
secondary_market 8.90
product_crowdfunding 8.90
round_A 8.90
round_B 8.90
round_C 8.90
round_D 8.90
round_E 8.90
round_F 8.90
round_G 8.90
round_H 8.90
dtype: float64

Выводим уникальные значения в столбцах с типом object

In [52]: `### Цикл для вывода всех уникальных object. Отключил вывод для github. Занимает много места но
#for i in investments.select_dtypes(include=['object']).columns:`

```
# print('')
# #print(i)
# display(investments[i].unique())
```

Выводим информацию о 2-ой таблице

In [6]: `view_info(returns)`

Информация о таблице

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 15 entries, 0 to 14

Data columns (total 14 columns):

#	Column	Non-Null Count	Dtype
0	year	15 non-null	int64
1	seed	15 non-null	float64
2	venture	15 non-null	float64
3	equity_crowdfunding	15 non-null	float64
4	undisclosed	15 non-null	float64
5	convertible_note	15 non-null	float64
6	debt_financing	15 non-null	float64
7	angel	15 non-null	float64
8	grant	15 non-null	float64
9	private_equity	15 non-null	float64
10	post_ipo_equity	15 non-null	float64
11	post_ipo_debt	15 non-null	float64
12	secondary_market	15 non-null	float64
13	product_crowdfunding	15 non-null	float64

dtypes: float64(13), int64(1)

memory usage: 1.8 KB

Случайные строки датасета

	year	seed	venture	equity_crowdfunding	undisclosed	convertible_note	debt_financing	angel	g
7	2007	70.41	3,585.37	0.01	55.37	3.22	125.68	164.51	
6	2006	61.81	3,100.18	0.19	46.74	1.78	113.21	47.75	
4	2004	9.93	555.90	0.00	33.19	0.01	13.55	9.18	
2	2002	6.59	209.42	0.00	25.77	0.02	3.42	3.41	
9	2009	160.21	2,501.29	0.18	37.50	2.25	394.10	97.21	

◀  ▶

Информация о пропусках

year	0.00
seed	0.00
venture	0.00
equity_crowdfunding	0.00
undisclosed	0.00
convertible_note	0.00
debt_financing	0.00
angel	0.00
grant	0.00
private_equity	0.00
post_ipo_equity	0.00
post_ipo_debt	0.00
secondary_market	0.00
product_crowdfunding	0.00

dtype: float64

Промежуточный вывод

В таблице `investments` 40 столбцов и 54293 строк с данными о компаниях.

При первом знакомстве видим следующее:

- Все столбцы содержат пропуски. Процент пропусков варьируется от 8.9 % до 44.4 %
- Столбцы связанные с инвестициями содержат равную долю пропусков - 8.9 %.
- В столбце `market` есть неявные дубликаты. Следует проверить все таблицу на их наличие и избавиться от них
- Столбец `funding_total_usd` следует привести к числовому типу, а столбцы: `founded_at`, `founded_month`, `founded_quarter`, `founded_year`, `first_funding_at`, `mid_funding_at` и `last_funding_at` к типу дат. Сейчас эти столбцы имеют тип `object`.

В таблице `returns` 14 столбцов и 15 строк с данными о финансировании.

На первый взгляд здесь отсутствуют аномальные значения. Пропусков в таблице нет.

Предобработка данных

Убираем лишние пробелы в названии столбцов

```
In [7]: investments.columns = investments.columns.str.strip()  
investments.columns
```

```
Out[7]: Index(['name', 'homepage_url', 'category_list', 'market', 'funding_total_usd',  
              'status', 'country_code', 'state_code', 'region', 'city',  
              'funding_rounds', 'participants', 'founded_at', 'founded_month',  
              'founded_quarter', 'founded_year', 'first_funding_at', 'mid_funding_at',  
              'last_funding_at', 'seed', 'venture', 'equity_crowdfunding',  
              'undisclosed', 'convertible_note', 'debt_financing', 'angel', 'grant',  
              'private_equity', 'post_ipo_equity', 'post_ipo_debt',  
              'secondary_market', 'product_crowdfunding', 'round_A', 'round_B',  
              'round_C', 'round_D', 'round_E', 'round_F', 'round_G', 'round_H'],  
              dtype='object')
```

Приведем `funding_total_usd` к числовому типу

```
In [8]: investments['funding_total_usd'] = pd.to_numeric(investments['funding_total_usd'].str.replace  
print(investments['funding_total_usd'].dtype)
```

float64

Исправим тип данных в столбцах с датами.

```
In [9]: #Цикл для изменения типа данных методом pd.to_datetime  
def to_date(columns):  
    for col in columns:  
        investments[col] = pd.to_datetime(investments[col], errors='coerce')  
  
to_date(['founded_at', 'founded_month', 'founded_quarter', 'first_funding_at', 'mid_funding_at',  
        'last_funding_at'])  
  
#Данные в этом столбце имеют числовой тип, поэтому не использую цикл.  
investments['founded_year'] = pd.to_datetime(investments['founded_year'].astype(str).str.replace('-', ''),  
                                              errors='coerce').dt.year  
  
investments[['founded_at', 'founded_month', 'founded_year', 'founded_quarter', 'first_funding_at', 'mid_funding_at',  
            'last_funding_at']] = investments[['founded_at', 'founded_month', 'founded_year', 'founded_quarter', 'first_funding_at', 'mid_funding_at',  
            'last_funding_at']].dt
```

```
Out[9]: founded_at      datetime64[ns]
founded_month    datetime64[ns]
founded_year      datetime64[ns]
founded_quarter   datetime64[ns]
first_funding_at  datetime64[ns]
mid_funding_at    datetime64[ns]
last_funding_at   datetime64[ns]
dtype: object
```

В датасете `cb_returns` сделаем столбец `year` индексом.

```
In [10]: returns = returns.set_index('year')
returns.head()
```

```
Out[10]:
```

	seed	venture	equity_crowdfunding	undisclosed	convertible_note	debt_financing	angel	grar
year								
2000	16.70	55.40	0.00	78.21	0.00	8.66	6.43	0.0
2001	2.88	23.49	0.00	21.50	0.01	4.49	1.18	0.0
2002	6.59	209.42	0.00	25.77	0.02	3.42	3.41	0.0
2003	7.74	233.86	0.00	9.40	0.01	1.09	3.41	0.0
2004	9.93	555.90	0.00	33.19	0.01	13.55	9.18	0.0



```
In [11]: print('Количество уникальнй значений до нормализации')
investments.select_dtypes(include=['object']).nunique()
```

Количество уникальнй значений до нормализации

```
Out[11]: name      49350
homepage_url  45850
category_list 16675
market        939
status         3
country_code  115
state_code     61
region       1089
city         4188
dtype: int64
```

Обработаем текстовые данные и приведем их к единому формату.

```
In [12]: for col in investments.select_dtypes(include=['object']):
investments[col] = investments[col].str.strip()
investments[col] = investments[col].str.lower()

print('Количество уникальнй значений после нормализации')
investments.select_dtypes(include=['object']).nunique()
```

Количество уникальнй значений после нормализации

```
Out[12]: name      49331
homepage_url  45846
category_list 16675
market        439
status         3
country_code  115
state_code     61
region       1089
city         4188
dtype: int64
```

Избавимся от полных дубликатов

```
In [13]: print('Количество полных дубликатов')
display(investments.duplicated().sum())

investments.drop_duplicates(inplace=True)
```

Количество полных дубликатов
np.int64(4855)

Заполним пропуски `funding_total_usd`. Вместо пропусков укажем общую сумму всех инвестиций в стартап.

```
In [14]: total_invested = investments.loc[:, 'seed':'product_crowdfunding'].sum(axis=1)
investments['funding_total_usd'] = investments['funding_total_usd'].fillna(total_invested)
```

Если строки не содержат сумму финансирования или дату первого финансирования, то отбросим их.

```
In [15]: investments.drop(investments[investments['funding_total_usd'] == 0].index, inplace=True)
investments.dropna(subset=['first_funding_at'], inplace=True)
```

Заполним пропуски в значениях `mid_funding_at` на основании значений в столбцах `first_funding_at` и `last_funding_at`. В качестве нового значения вместо пропусков возьмем середину интервала между этими двумя датами.

```
In [16]: mid_date = investments['first_funding_at'] + (investments['last_funding_at'] - investments['f
investments['mid_funding_at'] = investments['mid_funding_at'].fillna(mid_date)
```

Пропуски оставшиеся после обработки

```
In [17]: investments.isna().sum()
```

```
Out[17]: name 1
homepage_url 2314
category_list 2503
market 2503
funding_total_usd 0
status 1105
country_code 3819
state_code 15287
region 3819
city 4505
funding_rounds 0
participants 13575
founded_at 8707
founded_month 8772
founded_quarter 8772
founded_year 8707
first_funding_at 0
mid_funding_at 0
last_funding_at 0
seed 0
venture 0
equity_crowdfunding 0
undisclosed 0
convertible_note 0
debt_financing 0
angel 0
grant 0
private_equity 0
post_ipo_equity 0
post_ipo_debt 0
secondary_market 0
product_crowdfunding 0
round_A 0
round_B 0
round_C 0
round_D 0
round_E 0
round_F 0
round_G 0
round_H 0
dtype: int64
```

```
In [18]: print('Удалено строк на этапе предобработки')
display(original_size - investments.shape[0])
print('Доля оставшихся строк от изначального количества')
display(round(investments.shape[0] / original_size, 2))
print('Итоговый размер таблицы `investments`')
display(investments.shape[0:])
```

Удалено строк на этапе предобработки

13389

Доля оставшихся строк от изначального количества

0.75

Итоговый размер таблицы `investments`

(40905, 40)

Промежуточный вывод

На этапе предобработки данных мы привели данные к единому формату, изменили тип данных в некоторых столбцах и избавились от дубликатов и строк с недостаточным количеством данных для дальнейшего исследования:

- Столбцы с датами имели некорректный тип данных `object` или `float`. Привели их к типу `datetime`

- Избавились от большого количества дубликатов в столбце `market`, число уникальных значений в нем уменьшилось примерно в 2 раза.
- Избавились от 4855 строк полных дубликатов и от 8534 строк без информации о финансировании. Всего удалено 13389 строк.
- Было отброшено 25% строк

Итоговая таблица содержит достаточное количество строк для продолжения исследовательского анализа.

Исследовательский анализ по срокам финансирования и сегментам рынка

Выделяем группы по срокам финансирования

Разделим все компании на три группы:

- Единичное финансирование — был всего один раунд финансирования.
- Срок финансирования до года — между первым и последним раундом финансирования прошло не более года.
- Срок финансирования более года.

```
In [19]: investments['funding_group'] = None

days = (investments['last_funding_at'] - investments['first_funding_at']).dt.days

investments.loc[investments['funding_rounds'] == 1, 'funding_group'] = 'Единичное финансирование'
investments.loc[(investments['funding_rounds'] > 1) & (days < 365), 'funding_group'] = 'Срок до года'
investments.loc[(investments['funding_rounds'] > 1) & (days >= 365), 'funding_group'] = 'Срок более года'


investments['funding_group'].isna().sum()
```

```
Out[19]: np.int64(0)
```

```
In [20]: investments.groupby('funding_group')['name'].count().plot(kind='pie', autopct='%1.0f%%')
plt.title('Распределение количества компаний по сроку финансирования компаний')
plt.ylabel('')
plt.show()
```

Распределение количества компаний по сроку финансирования компаний

Единичное финансирование




Срок финансирования до года

Срок финансирования более года

```
In [21]: investments.groupby('funding_group')['funding_total_usd'].sum().plot(kind='pie', autopct='%1.1f%%',
plt.title('Распределение объема привлеченных средств в зависимости от срока финансирования')
plt.ylabel('')
plt.show()
```

Распределение объема привлеченных средств в зависимости от срока финансирования

Единичное финансирование



Срок финансирования до года

Срок финансирования более года

Промежуточный вывод

- Подавляющее большинство компаний (59 %) получили только единичное финансирование, забрав при этом треть всех денег (31 %).
- При этом компании со сроком финансирования более года составляют всего 30 % от общего числа, но привлекли 62 % всех средств.
- Группа с коротким периодом финансирования (до 1 года) остаётся самой малочисленной по обоим показателям — на неё приходится 11 % компаний и 7 % привлечённого капитала.

Выделение средних и нишевых сегментов рынка

Сгруппируем отрасли и рынки по их размеру.

Для этого создадем 3 сегмента:

- Если к рынку или отрасли относится более 120 компаний, то отнесем ее к массовым - `massive`
- От 35 до 120 включительно, средние - `mid`
- До 35 компаний, нишевые - `niche`

```
In [22]: market_counts = investments['market'].value_counts()  
market_category = pd.cut(market_counts, bins= [0, 34, 120, float('inf')], labels=['niche', 'm
```

```
market_category.value_counts().plot(kind='bar', color=['lightcoral', 'skyblue', 'orange'], rot=0)
```


```
for i, v in enumerate(market_category.value_counts().values): plt.text(i, v, str(v), ha='center', va='bottom')
```

```
plt.title('Количество сегментов по категориям') plt.xlabel('Категория') plt.ylabel('Количество  
сегментов') plt.grid(axis='y', alpha=0.3) plt.show()
```

Рассчитаем количество компаний в сегментах `niche` и `mid`

```
In [23]: investments['market_category'] = investments['market'].map(market_category).astype('object')
```

```
In [24]: filtered_market_counts = investments[investments['market_category'] != 'massive']['market_cat  
  
filtered_market_counts.plot(kind='bar', color=['lightcoral', 'skyblue'], rot=0)  
  
for i, v in enumerate(filtered_market_counts.values):  
    plt.text(i, v, str(v), ha='center', va='bottom')  
  
plt.title('Распределение компаний по сегментам рынка (без массовых)')  
plt.xlabel('')  
plt.ylabel('Количество компаний')  
plt.grid(axis='y', linestyle="--", alpha=0.3)  
plt.show()
```



Оставим в столбце `market` (название рынка или отрасли компании) только для массового сегмента. Для остальных заменим на значения на заглушки — `niche` для нишевых и `mid` для

средних.

```
In [25]: investments.loc[investments['market_category'] == 'mid', 'market'] = 'mid'
investments.loc[investments['market_category'] == 'niche', 'market'] = 'niche'
```

Промежуточный вывод

Мы выделили 3 категории в зависимости от количества компаний, которые находятся в каждом сегменте `market` :

- Нишевые (`niche`) - сегменты, в которых находится до 35 компаний
- Средние (`mid`) - от 35 до 120 компаний включительно
- Массовые (`massive`) - более 120 компаний

По количеству уникальных сегментов лидируют нишевые - к ним относится большинство направлений (289 сегментов), тогда как средних и массовых меньше (57 и 48 соответственно). При этом по числу компаний ситуация обратная: почти все они сосредоточены всего на 48 массовых рынках, где находится 33 733 компании. В средние сегменты попало 3 839 компаний, а на долю всех 289 нишевых направлений приходится минимум - всего 830 компаний.

Оставили сегменты только для массовой категории `massive`. Для остальных заменили значения на заглушки — `niche` для нишевых и `mid` для средних.

Работа с выбросами и анализ

Анализируем и помечаем выбросы в каждом из сегментов

Заказчика интересует обычный для рассматриваемого периода размер средств, который предоставлялся компаниям.

Оценим, какой размер общего финансирования для одной компании будет типичным, а какой — выбивающимся.


```
In [26]: investments['funding_total_usd'].describe()
```

```
Out[26]: count          40,905.00
mean         15,912,465.55
std          168,682,923.56
min              1.00
25%          350,000.00
50%          2,000,000.00
75%          10,000,000.00
max          30,079,503,000.00
Name: funding_total_usd, dtype: float64
```

```
In [27]: (investments['funding_total_usd'] / 1000000).plot(kind='box', vert=False, showfliers=False, f

plt.title('Распределение финансирования компаний')
plt.xlabel('Сумма финансирования (в млн. USD)')
plt.grid(axis= 'x', linestyle="--", alpha=0.3)
plt.show()
```

Распределение финансирования компаний



Определим компании с аномальным объёмом общего финансирования — используя метод IQR отдельно по каждому сегменту.

```
In [28]: investments['is_anomaly'] = False

for market_name in investments['market'].unique():

    q1 = investments[investments['market'] == market_name]['funding_total_usd'].quantile(0.25)
    q3 = investments[investments['market'] == market_name]['funding_total_usd'].quantile(0.75)
    upper_bound = q3 + 1.5 * (q3 - q1)

    investments.loc[(investments['market'] == market_name) & (investments['funding_total_usd']
In [29]: investments.groupby('market')['is_anomaly'].mean().sort_values(ascending=False)
```

```
Out[29]: market
real estate      0.17
entertainment    0.17
consulting       0.17
search           0.16
cloud computing  0.16
saas             0.16
photography      0.16
technology       0.16
video            0.16
niche            0.16
travel           0.15
networking       0.15
internet         0.15
big data         0.15
marketplaces     0.15
mid              0.14
e-commerce       0.14
apps             0.14
automotive       0.14
medical          0.14
sports           0.14
social media     0.14
news             0.13
education        0.13
fashion          0.13
mobile           0.13
hospitality      0.13
health and wellness 0.13
messaging        0.13
clean technology 0.13
startups         0.13
social network media 0.13
finance          0.13
music            0.12
analytics        0.12
advertising      0.12
software         0.12
public relations 0.12
curated web      0.12
security         0.12
hardware + software 0.12
design            0.11
health care      0.11
biotechnology    0.11
enterprise software 0.11
manufacturing    0.11
games            0.10
web hosting       0.10
nonprofits       0.10
semiconductors   0.07
Name: is_anomaly, dtype: float64
```

Промежуточный вывод

- В выборке из 40 905 компаний медианный объем общего финансирования составил 2 млн долларов, что можно считать типичным уровнем инвестиций для одной компании.
- Основная часть компаний получила финансирование в диапазоне от 350 тыс. до 10 млн долларов (25–75-й перцентили), поэтому этот диапазон можно считать наиболее характерным для рассматриваемого периода.

- Среднее значение финансирования (15,9 млн долларов) выше медианного (2 млн долларов), что связано с наличием компаний, которые привлекли значительно больше средств, чем большинство стартапов.
- Максимальное значение финансирования (около 30 млрд долларов) существенно превышает типичные значения
- Наибольшая доля компаний с аномально высоким финансированием наблюдается в сегментах `real estate`, `entertainment` и `consulting` — около 17% компаний.
- В технологических сегментах (`search`, `cloud computing`, `saas`, `technology`) доля аномальных значений также находится на высоком уровне — около 16%.
- Самая низкая доля компаний с аномальным финансированием отмечена в сегменте `semiconductors` — около 7%.

Определяем границы рассматриваемого периода, отбрасываем аномалии

Проверяем наличие данных за 2014 год

```
In [30]: data_for_2014 = investments[(investments['first_funding_at'] >= '01-01-2014') & (investments['first_funding_at'] <= '12-31-2014')]
print('Объем данных за 2014 год:', data_for_2014.shape)
print('Минимум:', data_for_2014['first_funding_at'].min())
print('Максимум:', data_for_2014['first_funding_at'].max())
```

Объем данных за 2014 год: (6477, 43)

Минимум: 2014-01-01 00:00:00

Максимум: 2014-12-31 00:00:00

Исключим компании, которые получили аномальное финансирование

```
In [31]: print("Было строк:", investments.shape[0])
investments = investments.loc[~investments['is_anomaly']]
print("Осталось строк:", investments.shape[0])
```

Было строк: 40905

Осталось строк: 36034

В соответствии с техническим заданием фильтруем таблицу оставляя строки с годами, в которых было более 50 раундов.

```
In [32]: year_rounds = investments.groupby(investments['mid_funding_at'].dt.year)['funding_rounds'].sum()
investments = investments.loc[investments['mid_funding_at'].dt.year.isin(year_rounds[year_rounds > 50].index)]
```

Промежуточный вывод

- По данным за 2014 год в датасете представлено 6 477 компаний, при этом период полностью покрывает весь год: с 1 января по 31 декабря 2014 года. Это позволяет считать данные за 2014 год полными в рамках предоставленного набора.
- После удаления компаний с аномально высоким финансированием количество записей уменьшилось с 40 905 до 36 034.

Анализ типов финансирования по объёму и популярности


Привлеченные инвестиции в зависимости от типа финансирования в миллионах долларов США

```
In [33]: funding_by_type = investments.loc[:, 'seed':'product_crowdfunding'].sum().sort_values(ascendi
```

```
In [34]: (funding_by_type / 1000000).plot(kind='barh', figsize=(10, 5), color='skyblue')
```

```
for i, v in enumerate((funding_by_type / 1000000).values):
    label = f'{v:.0f} млн. USD'
    plt.text(v, i, label, ha='left', va='center', fontsize=10)

plt.title('Привлеченные инвестиции в зависимости от типа финансирования')
plt.xlabel('Сумма в миллионах долларов')
plt.grid(axis='x', linestyle="--", alpha=0.3)
plt.show()
```




Популярность типов финансирования

```
In [35]: count_by_type = (investments.loc[:, 'seed':'product_crowdfunding'] > 0).sum().sort_values(asc
```

```
In [36]: count_by_type.plot(kind='barh', figsize=(10, 5), color='skyblue')
```

```
for i, v in enumerate(count_by_type.values):
    label = f'{v:.0f}'
    plt.text(v, i, label, ha='left', va='center', fontsize=10)

plt.title('Популярность типов финансирования')
plt.xlabel('Случаев финансирования')
plt.grid(axis='x', linestyle="--", alpha=0.3)
plt.show()
```




Средняя сумма финансирования по типам в миллионах

```
In [37]: average_by_type = (funding_by_type / count_by_type).sort_values(ascending=True)
```

```
In [38]: (average_by_type / 1000000).plot(kind='barh', figsize=(10, 5), color='skyblue')
```

```
for i, v in enumerate((average_by_type / 1000000).values):
    label = f'{v:.1f} млн. USD'
    plt.text(v, i, label, ha='left', va='center', fontsize=10)

plt.title('Средняя сумма финансирования по типам в миллионах')
plt.xlabel('Сумма в миллионах долларов')
plt.ylabel('Тип финансирования')
plt.grid(axis='x', linestyle="--", alpha=0.3)
plt.show()
```




Объем возвратов в зависимости от типа финансирования

```
In [39]: returns.sum().sort_values().plot(kind='barh', figsize=(10, 4), color='skyblue')
```

```
for i, v in enumerate(returns.sum().sort_values().values):
    label = f'{v:.1f} млн. USD'
    plt.text(v, i, label, ha='left', va='center', fontsize=10)

plt.title('Объем возвратов в зависимости от типа финансирования')
plt.xlabel('Сумма в миллионах долларов')
```

```
plt.ylabel('Тип финансирования')
plt.grid(axis='x', linestyle="--", alpha=0.3)
plt.show()
```



Промежуточный вывод

- Наибольший общий объем привлеченных средств приходится на венчурный тип финансирования (`venture`) — почти 134 млрд долларов, что значительно превышает остальные виды финансирования.
- Венчурное (`venture`) финансирование встречается чаще всего (19 060 случаев), а на втором месте находятся посевные (`seed`) инвестиции (13 388 случаев). При этом `seed` имеет значительно меньший общий объем инвестиций, чем `venture` .
- Некоторые типы финансирования встречаются редко, но имеют высокий средний объем. Например, `post_ipo_debt` , `post_ipo_equity` и `private_equity` используются реже, но отличаются крупными суммами финансирования.
- Небольшие по объему и часто встречающиеся типы финансирования — `seed` и `angel` . Их суммарные объемы сильно ниже, чем у `venture` , несмотря на то, что разница в популярность не большая.
- По объему возврата средств лидирует `venture` - около 40,6 млрд долларов, далее идут `debt_financing` (4,7 млрд) и `private_equity` (3,6 млрд). Это показывает, что наиболее значимые возвраты за весь период связаны с крупными инвестиционными направлениями.

Анализ динамики

Динамика предоставления финансирования по годам

Динамика типичного размера средств, которые стартапы получали в рамках одного раунда финансирования

```
In [40]: investments['funding_per_round'] = investments['funding_total_usd'] / investments['funding_rounds']
avg_per_round = round(investments.groupby(investments['mid_funding_at'].dt.year)['funding_per_round'].mean())
```

```
In [41]: avg_per_round.plot(kind='bar', figsize=(10, 5), rot=0, color='skyblue')

for i, v in enumerate(avg_per_round.values):
    plt.text(i, v, str(v), ha='center', va='bottom')

plt.title('Средняя сумма средств в млн. USD, которые получали стартапы за раунд финансирования')
plt.xlabel('Год')
plt.ylabel('Сумма в млн. USD')
```

```
plt.grid(axis='y', linestyle="--", alpha=0.5)
plt.show()
```



Общее количество раундов финансирования в году

```
In [42]: count_rounds = investments.groupby(investments['mid_funding_at'].dt.year)['funding_rounds'].size()
```

```
In [43]: count_rounds.plot(kind='bar', figsize=(10, 5), rot=0, color='skyblue')
```

```
for i, v in enumerate(count_rounds.values):
    plt.text(i, v, str(v), ha='center', va='bottom')

plt.title('Количество раундов финансирования в году')
plt.xlabel('')
plt.grid(axis='y', linestyle="--", alpha=0.5)
plt.show()
```



- Максимальный средний объем финансирования в расчете на один раунд наблюдался в 2005 году и составил около 5,86 млн долларов. Высокие значения также фиксировались в 2004–

2007 годах, после чего показатель постепенно снижался.

- Начиная с 2008 года типичный размер одного раунда финансирования демонстрировал нисходящую динамику и достиг минимального значения в 2013 году - около 2,21 млн долларов.
- При этом, общее количество раундов финансирования практически росло: с 122 в 2000 году до 12 945 в 2013 году.
- В 2014 году произошли изменения: количество проведенных раундов сократилось до 7 244, при этом средний объем финансирования одного раунда увеличился до 3,74 млн долларов по сравнению с предыдущим годом.
- Получается, что в 2014 году инвестиций стало проводиться меньше, но в среднем на один раунд выделялось больше средств, чем годом ранее.

Динамика размера общего финансирования по массовым сегментам рынка для растущих в 2014 году сегментов

Размер общего финансирования `funding_total_usd` по годам и сегментам рынка.

```
In [44]: investments['funding_year'] = investments['mid_funding_at'].dt.year
funding_pivot = investments.pivot_table(index='market', columns='funding_year', values='funding_total_usd')
```

```
In [45]: result_pivot = funding_pivot.loc[funding_pivot[2014] > funding_pivot[2013]]
result_pivot = result_pivot.drop(index=['niche', 'mid'], errors='ignore')
result_pivot
```

Out[45]:

funding_year	2000	2001	2002	2003	2004	2005	
market							
apps	NaN	NaN	NaN	NaN	NaN	NaN	1
big data	NaN	NaN	NaN	NaN	NaN	NaN	
design	NaN	NaN	NaN	NaN	NaN	9,300,000.00	
internet	10,000,000.00	NaN	1,100,000.00	NaN	10,500,000.00	1,775,000.00	
manufacturing	56,659,310.00	2,368,582.00	NaN	4,269,608.00	3,000,000.00	61,770,000.00	163
medical	24,000,000.00	NaN	NaN	NaN	NaN	11,090,000.00	20
real estate	2,500,000.00	NaN	5,275,000.00	6,292,200.00	NaN	250,000.00	2
saas	NaN	NaN	2,000,000.00	NaN	NaN	5,240,000.00	4
startups	NaN	NaN	NaN	NaN	NaN	NaN	
technology	NaN	22,160,000.00	11,000,000.00	NaN	1,750,000.00	50,728,425.00	22


Оставим только те года, за которые есть данные (с 2008 года)

```
In [46]: (result_pivot.loc[:, result_pivot.columns >= 2008] / 1000000).T.plot(kind='line', marker='o',

plt.title('Динамика финансирования массовых сегментов рынка')
plt.xlabel('Год')
plt.ylabel('Сумма млн. USD')
plt.grid(axis='y', linestyle="--", alpha=0.5)
plt.legend(bbox_to_anchor=(1.05, 1), title='Сегменты')

plt.show()
```

Динамика финансирования массовых сегментов рынка



- Среди массовых сегментов были отобраны только те, в которых общий объем финансирования в 2014 году оказался выше, чем в 2013 году.
- Сегменты `technology` и `medical` показали уверенный рост. В 2014 году сумма привлеченных инвестиций в них значительно увеличилась по сравнению с предыдущим годом.
- Сегменты `internet`, `apps`, `real estate` и `startups` также продемонстрировали рост финансирования в 2014 году, хотя он был менее выраженным.
- Можно сделать вывод, что в 2014 году инвесторы стали активнее вкладывать средства в технологические (`technology`) и медицинские компании (`medical`).

Годовая динамика доли возвращённых средств по типам финансирования

Доля возвращенных средств для каждого года и вида финансирования

```
In [47]: funding_by_year = investments.groupby('funding_year')[investments.loc[:, 'seed': 'product_crowd']]
return_by_year = (returns.groupby('year')[investments.loc[:, 'seed': 'product_crowd']].sum())
ratio_table = return_by_year / (funding_by_year + 1e-60)
ratio_table = ratio_table[ratio_table <= 1.0]
ratio_table
```

Out[47]:

	seed	venture	equity_crowdfunding	undisclosed	convertible_note	debt_financing	angel	gran
year								
2000	1.00	0.15	0.00	0.36	0.00	0.62	0.27	0.00
2001	0.11	0.08	0.00	0.46	0.01	0.77	NaN	0.00
2002	0.63	0.61	0.00	0.61	NaN	0.22	NaN	0.00
2003	0.51	0.58	0.00	0.91	NaN	NaN	0.61	0.00
2004	0.55	0.77	0.00	0.34	NaN	0.44	0.83	0.00
2005	0.67	0.54	0.00	NaN	NaN	0.34	0.51	0.00
2006	0.93	0.34	0.20	0.65	0.15	0.80	0.67	0.00
2007	0.37	0.30	NaN	0.50	0.23	0.19	0.82	0.00
2008	0.30	0.19	NaN	0.29	0.06	0.93	0.41	0.00
2009	0.56	0.16	0.09	0.38	0.05	0.27	0.62	0.00
2010	0.53	0.18	0.05	0.24	0.07	0.32	0.64	0.00
2011	0.27	0.25	0.10	0.22	0.05	0.50	0.44	0.00
2012	0.19	0.31	0.03	0.12	0.05	0.49	0.50	0.00
2013	0.15	0.35	0.02	0.24	0.05	0.37	0.54	0.00
2014	0.28	0.69	0.01	0.16	0.07	0.20	NaN	0.00

График нормирования значения возврата средств для типов финансирования `venture` , `debt_financing` , `private_equity` , `seed` и `angel` .

In [48]:

```
for finance_type in ['venture', 'debt_financing', 'private_equity', 'seed', 'angel']:
    plt.figure(figsize=(8, 4))


    ratio_table[finance_type].plot(kind='line', marker='o', figsize=(6, 4))

    plt.xticks(ratio_table.index, rotation=45)


    plt.title(f'Динамика возврата средств для типа: {finance_type}')
    plt.xlabel('Год')
    plt.ylabel('Доля возврата')
    plt.ylim(0, 1)
    plt.grid(linestyle="--", alpha=0.5)


    plt.show()
```

Динамика возврата средств для типа: venture



Динамика возврата средств для типа: debt_financing







- Наиболее устойчивый рост показателя возврата средств наблюдается у **venture**. После относительно низких значений в 2008–2010 годах доля возврата постепенно увеличивалась и к 2014 году достигла 0,69.
- Для **private_equity** показатель сильно менялся от года к году. Несмотря на отдельные высокие значения, устойчивый росту не наблюдается.
- **Seed** также не показывает рост. После высоких значений в начале периода доля возврата постепенно снижалась, а в 2014 году немного выросла.
- У **debt_financing** значения заметно колебались на протяжении всего периода. Показатель несколько раз резко увеличивался и снижался.
- Для **angel** доля возврата в разные годы также менялась неравномерно, а в 2014 году значение отсутствует, поэтому сделать вывод о стабильном росте невозможно.

Таким образом, среди рассмотренных типов финансирования положительную динамику демонстрирует только **venture**, тогда как остальные типы имеют значительными колебаниями показателя возврата средств.

Итоговый вывод и рекомендации

Рекомендация для заказчика

На основе проведенного анализа можно рекомендовать обратить внимание на технологический и медицинский сегменты рынка. В 2014 году эти направления показали рост объемов привлеченного финансирования по сравнению с предыдущим годом. Также интерес инвесторов сохранялся к сегментам **internet** и **saas**, которые показывали рост в последние годы.

В качестве типа финансирования наиболее перспективным вариантом выглядит венчурный тип финансирования. Данный тип инвестиций является самым распространенным по количеству сделок и объему вложенных средств. Кроме того, именно для него наблюдается наиболее стабильная динамика возврата средств среди рассмотренных типов финансирования.

Итоговый вывод

В рамках проекта были выполнены следующие этапы:

- Проведена подготовка данных: обработаны пропуски, удалены дубликаты, проверена корректность временных и числовых значений.
- Выполнен анализ структуры финансирования стартапов: исследованы различные типы инвестиций, их объемы и популярность среди компаний.
- Рассчитаны средние объемы финансирования одного раунда и изучена динамика инвестиционной активности по годам.
- Проведен анализ массовых сегментов рынка и выявлены направления, которые показывали рост финансирования в 2014 году.
- Рассчитана доля возврата средств для разных типов финансирования и проведено сравнение их эффективности.

По результатам анализа было установлено, что венчурное инвестирование является наиболее значимым направлением: оно лидирует по объему вложенных средств, количеству сделок и возвратам инвестиций. Также было выявлено, что в 2014 году инвесторы проявляли повышенный интерес к технологическим и медицинским компаниям.

При этом некоторые выводы требуют осторожной интерпретации. Например, высокий объем финансирования не всегда означает более высокую эффективность инвестиций, так как крупные направления могут иметь большие абсолютные возвраты, но не обязательно лучший процент возврата. Кроме того, показатели отдельных типов финансирования сильно менялись по годам, поэтому для принятия окончательного инвестиционного решения потребовался бы дополнительный анализ отдельных компаний и рисков.

В целом результаты анализа согласуются между собой и показывают, что на момент 2015 года наиболее перспективным направлением выглядело инвестирование в технологические и медицинские стартапы через венчурное финансирование.

In []: